

# Modelo de Computação Probabilístico e Suas Aplicações

Ediana da Silva de Souza, Erica Peters do Carmo

*Santa Catarina, Brasil*

---

## Abstract

A Teoria da Computação define uma máquina de Turing probabilística como uma máquina de Turing não-determinística que escolhe cada transição de acordo com um processo aleatório. Este artigo apresenta a definição do modelo de computação probabilístico e suas classes de complexidade, bem como a classificação destes algoritmos de acordo com seus objetivos e algumas de suas aplicações. De forma a conceituar os tópicos propostos, a metodologia adotada para a elaboração deste trabalho caracteriza-se como uma pesquisa bibliográfica. Como resultado, entende-se que alguns problemas podem ser solucionados de maneira eficiente por algoritmos probabilísticos, isto demonstra a importância do estudo acerca do tema.

*Keywords:* Máquina de Turing Probabilística, Teoria da Computação, Computabilidade, Não-Determinismo

---

## 1. Introdução

Algoritmos probabilísticos são algoritmos que utilizam em seu processamento o resultado de algum evento aleatório. Antes vistos apenas como uma ferramenta para a Teoria dos Números, hoje, esses algoritmos são utilizados em diversas áreas de aplicação principalmente devido à duas de suas características principais: simplicidade e velocidade [1].

Historicamente, define-se que a utilização desses algoritmos teve início com os métodos Monte Carlo utilizados na análise numérica e estatística. Já em Teoria da Computação, [2], [3], [4] e [5] fazem as primeiras menções às máquinas de Turing probabilísticas.

Com o intuito de apresentar uma pesquisa bibliográfica relacionada à computação probabilística, este trabalho explana acerca da definição das máquinas de Turing probabilísticas, suas classes de complexidade, classificações e aplicações.

Assim, a seção 2 apresenta a definição de máquina de Turing probabilística enquanto a seção 3 explana sobre as classes probabilísticas. A seção 4 apresenta a classificação dos algoritmos probabilísticos e a seção 5 aborda duas de suas aplicações. Finalmente, a seção 6 apresenta as considerações finais.

## 2. Definição

Em Teoria da Computação, a primeira menção à máquina de Turing probabilística aparece em [2]. Posteriormente, o termo foi explorado e definido em [3], [4] e [5]. Nesse sentido, o presente trabalho apresenta três definições de máquinas de Turing probabilísticas de acordo com os primeiros trabalhos exploratórios acerca do termo.

DEFINIÇÃO I. De acordo com Rabin em [3], um autômato probabilístico (p.a.) sobre o alfabeto  $\Sigma$  é um sistema  $\mathfrak{V} = \{S, M, s_0, F\}$  onde  $S = \{s_0, \dots, s_n\}$  é um conjunto finito de estados,  $s_0$  é o estado inicial,  $F$  é o conjunto de estados finais e  $M$  é uma função  $S \times \Sigma \rightarrow [0, 1]^{n+1}$  (tabela de transições possíveis) onde para cada transição  $(s, \sigma) \in S \times \Sigma$ :

$$M(s, \sigma) = (p_0(s, \sigma), \dots, p_n(s, \sigma)), \text{ com } 0 \leq p_i(s, \sigma) \text{ e } \sum_i p_i(s, \sigma) = 1.$$

Assim, cada transição  $(s, \sigma)$  pode chegar a  $i = n + 1$  próximos estados com probabilidade  $p_i$ . Assume-se ainda que essas probabilidades permanecem fixas independente da entrada da máquina e do tempo de computação.

DEFINIÇÃO II. Gill em [5] define uma máquina de Turing probabilística como uma máquina de Turing não determinística [6] com estados adicionais chamados de estados de arremesso-de-moeda. Para cada um desses estados, a função de computação da máquina define dois próximos estados possíveis. Assim, a computação da máquina depende da sua entrada e do resultado dos arremessos de moeda que em cada passo não determinístico decidem entre os dois próximos estados. De maneira geral, para cada entrada  $x$ , uma máquina probabilística  $M$  produz  $y$  como saída com probabilidade  $Pr\{M(x) = y\}$ .

Assim como [7], este trabalho utiliza a definição de Gill [5] para apresentar as seguintes definições relacionadas aos erros e probabilidades das máquinas probabilísticas de Turing:

Seja  $b$  um ramo da computação não determinística de  $M$  sobre uma entrada  $w$  e  $k$  o número de passos do tipo arremesso-de-moeda que ocorrem no

50 ramo  $b$ , a probabilidade de aceitação do ramo é:

51

$$52 \quad Pr[b] = 2^{-k}$$

53

54 e a probabilidade da entrada  $w$  ser aceita por  $M$  é:

55

$$56 \quad Pr[M \text{ aceita } w] = \sum Pr[b].$$

57

58 Define-se ainda que para uma máquina de Turing probabilística reco-  
59 nhecer uma linguagem, ela deve aceitar todas as palavras pertencentes à  
60 linguagem e rejeitar todas as palavras não pertencentes, com uma probabili-  
61 dade de erro  $\epsilon$  [7]. Assumindo  $0 \leq \epsilon < \frac{1}{2}$ ,  $M$  reconhece uma linguagem  $L$  com  
62 probabilidade de erro  $\epsilon$  se:

63

$$64 \quad 1. w \in L \implies Pr[M \text{ aceita } w] \geq 1 - \epsilon, \text{ e}$$

$$65 \quad 2. w \notin L \implies Pr[M \text{ rejeita } w] \geq 1 - \epsilon.$$

66


67 Assim, é possível afirmar que ao simular  $w$  em  $M$  a probabilidade máxima  
68 de obter um resultado errado é de  $\frac{1}{2}$ .

69 A Figura 1 apresenta um exemplo de computação de uma máquina de  
70 Turing probabilística - sem definir os movimentos do cabeçote e a escrita na  
71 fita. Observa-se na figura que  $s_0$ ,  $s_1$  e  $s_2$  são estados de arremesso-de-moeda e  
72 a soma das probabilidades de cada transição originadas nesses estados resulta  
73 em 1. Verifica-se que a partir de uma entrada  $w$  qualquer,  $Pr[M \text{ aceita } w] = 0,71$ . Logo,  $w \in L(M)$  e a probabilidade de erro de  $M$  é 0,29. Logo,  
74  $L(M) \in BPP$ .  
75

76 Outra questão referente à máquina de Turing probabilística é se seu po-  
77 der computacional difere-se do poder de um modelo comum de máquina de  
78 Turing. [5] e [4] provaram que a resposta para essa questão é negativa e um  
79 jeito simples de entender essa prova é a partir de uma outra definição para a  
80 máquina de Turing probabilística:

81 DEFINICAO III. De acordo com Mandrioli et al. [8], é possível enten-  
82 der uma máquina de Turing probabilística como uma máquina de Turing  
83 multifita. Além da fita principal de trabalho, a máquina possui uma fita  
84 especial preenchida aleatoriamente com bits. Assim, a cada passo da função  
85 de transição, a máquina verifica o bit sob o cabeçote da fita especial, move  
86 o cabeçote para a direita e faz um movimento de transição de acordo com o  
87 valor do bit lido. Em uma mesma transição é possível definir movimentos di-

Figura 1: Computação de uma máquina de Turing probabilística



ferentes para os bits 0 e 1, isso representa um estado de arremesso-de-moeda, onde o valor do bit equivale ao valor obtido aleatoriamente no arremesso de uma máquina de Turing probabilística.

Como explanado em [7], a máquina de Turing multifita tem o mesmo poder computacional de uma máquina de Turing comum. Assim, entende-se que o fator aleatório não adiciona poder computacional, tudo que uma máquina de Turing probabilística computa pode ser computado por uma máquina de Turing normal.

Contudo, o comportamento da máquina de Turing probabilística difere-se dos demais modelos, principalmente no que diz respeito à possibilidade de erro do seu resultado. Esse fator está diretamente relacionado à análise da sua complexidade, explorada na próxima seção.

### 3. Classes Probabilísticas

Através da análise da complexidade de tempo é possível definir classes de complexidade, sendo este um critério para classificar linguagens. No decorrer

desta seção será abordada a definição das classes probabilísticas BPP, RP e ZPP, bem como suas relações com NP e P. A partir deste ponto, o termo algoritmos probabilísticos será também utilizado para referir-se às máquinas de Turing probabilísticas.

### 3.1. Definição da classe BPP

A classe de complexidade BPP (bounded-error probabilistic polynomial time) compreende os problemas que podem ser resolvidos por máquinas de Turing probabilísticas de tempo polinomial com uma probabilidade de erro de  $\frac{1}{3}$  [7]. Isso significa que, dado uma linguagem  $L$ , ela está em BPP se e somente se existe uma máquina de Turing probabilística  $M$ , tal que [9]:

- Possui um algoritmo de tempo polinomial para o pior caso, ou seja,  $M$  é executada em tempo polinomial em toda entrada
- Se  $x \in L$ , então  $M$  aceita  $x$  com probabilidade  $\geq \frac{2}{3}$
- Se  $x \notin L$ , então  $M$  aceita  $x$  com probabilidade  $\leq \frac{2}{3}$

A classe BPP contém os algoritmos probabilísticos com erro de dois lados. Isto é, permite que a máquina  $M$  produza uma probabilidade de erro tanto se  $x \in L$  como se  $x \notin L$  [10].

Existem mudanças acerca das restrições do pertencimento de uma linguagem  $L$  em BPP, como visto em [11], na qual menciona que a probabilidade de erro nesta classe é de no máximo de  $\frac{1}{4}$ , sendo que se  $x \in L$ , então  $M$  aceita  $x$  com probabilidade  $\geq \frac{3}{4}$  e se  $x \notin L$ , então  $M$  aceita  $x$  com probabilidade  $\leq \frac{1}{4}$ . Do mesmo mesmo, [12] refere-se a classe BPP com a probabilidade de erro de  $\frac{1}{4}$ , sendo que se  $x \in L$ , pelo menos  $\frac{3}{4}$  dos caminhos de computação de  $M$  em  $x$  irão aceitá-lo e se  $x \notin L$ , pelo menos  $\frac{3}{4}$  dos caminhos de computação de  $M$  irão rejeitá-lo. Por fim, o autor [9] cita que a definição padrão refere-se a máquinas probabilísticas com uma probabilidade de erro de no máximo  $\frac{1}{3}$ . Essas mudanças sucedem pois a classe pode ser definida com qualquer probabilidade de erro constante estritamente entre 0 e  $\frac{1}{2}$ , conforme [7] e [13].

### 3.2. Definição da classe RP

A classe de complexidade RP (*randomized polynomial time*) é definida como sendo a classe de linguagens que são reconhecidas por máquinas de Turing probabilísticas de tempo polinomial em que entradas na linguagens são aceitas com uma probabilidade de, no mínimo,  $\frac{1}{2}$  e que entradas que não

estão na linguagem são rejeitadas com uma probabilidade de 1 [7]. Diferentemente da classe BPP que possui erros de ambos os lados, apresentando erros tanto se a linguagem aceita ou rejeita tal entrada, a classe RP possui uma característica chamada de erro unilateral. Isto é, quando o algoritmo produz uma resposta *não*, esta é sempre certa, quando produz uma resposta *sim*, esta pode estar errada [7]. Portanto, uma linguagem L pertence à classe RP se e somente se existir uma máquina de Turing probabilística M tal que para todo  $x \in \Sigma^*$  [14]:

- Se  $x \in L$ , então M aceita  $x$  com probabilidade  $\geq \frac{1}{2}$
- Se  $x \notin L$ , então M rejeita  $x$

A fração  $\frac{1}{2}$  na definição é arbitrária, visto que o conjunto RP conterá exatamente os mesmos problemas se o valor for substituído por qualquer probabilidade constante diferente de zero e inferior a 1 [15].

### 3.3. Definição da classe ZPP

A classe de complexidade ZPP (*zero-error probabilistic polynomial time*) é estabelecida como a classe de linguagens de erro bilateral, isto acontece porque a classe é definida como sendo  $RP \cup coRP$ , onde possui duas máquinas de Turing probabilísticas, uma que não tem falsos positivos e outra que não tem falsos negativos. Ou seja, podemos executar cada uma das máquinas alternadamente até que uma resposta definitiva possa ser obtida [16]. Portanto, uma linguagem L pertence à classe ZPP se e somente se existir uma máquina de Turing probabilística M tal que para todo  $x \in \Sigma^*$  [14]:


- M retorna que aceita com alta probabilidade de  $x \in L$
- M retorna que rejeita com alta probabilidade de  $x \notin L$
- M nunca retorna que aceita se  $x \notin L$
- M nunca retorna que rejeita se  $x \in L$

Portanto, esta classe não é idêntica a classe de máquina de Turing determinísticas, uma vez que esta ainda possui uma certa indecisão na sua resposta e não é possível saber quando sua execução vai terminar [14].

165 3.4. Classe probabilísticas e suas relações com NP e P

166 As classes P e NP são importantes definições em teoria da complexidade.  
167 A primeira é definida como sendo a classe de linguagens que são decidíveis em  
168 tempo polinomial por uma máquina de Turing determinística [7]. Já a classe  
169 NP recebe a definição de ser a classe de linguagens que são decidíveis em  
170 tempo polinomial por uma máquina de Turing não determinística ou que são  
171 verificadas em tempo polinomial por uma máquina de Turing determinística  
172 [7]. Na figura 2 é apresentada a relação destas classes com BPP, RP e ZPP.  
173 Desta figura é possível perceber que  $P \subset ZP \subset RP \subset BPP$ , bem como  $RP$   
174  $\subset NP$  e  $BP \subset NP$ . A classe de complexidade PP não será abordada neste  
175 trabalho.

Figura 2: Relação Entre as Classes de Complexidade



176 Esta subseção tem como foco a classe BPP e as relações com P e NP,  
177 visto que esta engloba as outras descritas. Sabe-se que  $P \subset BPP$ , uma  
178 vez que uma máquina de Turing determinista é um caso especial de uma  
179 máquina de Turing probabilística [10]. Porém, a questão se  $BPP = P$  ainda  
180 é uma questão aberta na teoria da complexidade, julgada tão importante  
181 quanto descobrir se  $NP = P$  [17]. Acredita-se que a igualdade entre BPP e  
182 P procede, e se comprovado, revelará que todo algoritmo probabilístico pode  
183 ser substituído por um algoritmo determinístico [17]. Caso provado que  $BPP$   
184  $= P$ , então teríamos que  $BPP \subset NP$ , visto que  $P \subset NP$ . Sobre a relação da  
185 classe BPP e NP, não sabe-se sobre sua relação de continência ou igualdade.  
186 As referências [5], [14] e [18] acreditam que seja improvável que  $NP \subset BPP$ .  
187 Portanto, acredita-se que nem todos os problemas do NP admitem algoritmos

188 aleatórios eficientes. Sendo assim, a busca por algoritmos aleatórios eficientes  
189 para problemas NP-completos é uma questão de pesquisa.

## 190 4. Classificação dos Algoritmos Probabilísticos

191 Os algoritmos probabilísticos podem ser divididos em dois principais gru-  
192 pos: Monte Carlo e Las Vegas. Nesta seção será apresentada suas definições  
193 e um exemplo acerca de suas implementações.

### 194 4.1. Definições

195 Os algoritmos Monte Carlo podem ser divididos em algoritmo com proba-  
196 bilidade de erro bilateral e probabilidade de erro unilateral, sempre execu-  
197 tados em tempo polinomial, sendo eles pertencentes a classe de complexidade  
198 BPP e RP, respectivamente [19]. Isto é, o primeiro descreve um algoritmo  
199 que pode retornar respostas erradas tanto se a resposta correta for falsa ou  
200 verdadeira. Já o segundo, têm-se que se a resposta correta for falsa, o al-  
201 goritmo indica isso, mas ele pode responder incorretamente em alguns casos  
202 em que a resposta correta é verdadeira [11].

203 Os algoritmos Las Vegas são aqueles que sempre dão a solução correta,  
204 mas podem variar seu tempo de execução para uma determinada entrada,  
205 não executando sempre em tempo polinomial. Estes são pertencentes a classe  
206 de complexidade ZPP [19].

207 A escolha de qual algoritmo utilizar depende do objetivo da aplicação. Se  
208 é preciso garantia de tempo, em todas as execuções, o algoritmo Monte Carlo  
209 é mais indicado. Se há necessidade de se estar sempre diante da resposta  
210 correta, o uso do Las Vegas vem a ser o mais apropriado [20]. É possível obter  
211 a construção de um algoritmo de Las Vegas para um problema na qual existe  
212 algoritmo de Monte Carlo e vice-versa, porém, nem sempre isto apresenta um  
213 desempenho suficientemente interessante [20]. Portanto, é preciso escolher  
214 entre a certeza ou o desempenho.

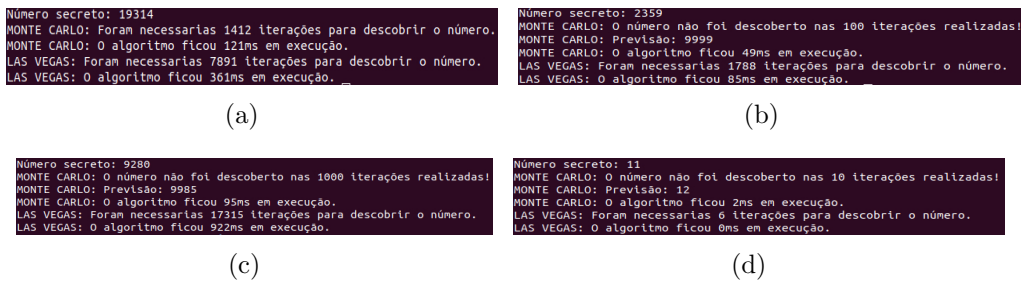
### 215 4.2. Implementação

216 Como forma de retratar a ideia dos algoritmos de Monte Carlo e Las Ve-  
217 gas, [21] criou um simples exemplo na qual busca encontrar um valor secreto  
218 gerado aleatoriamente. O código fonte do algoritmo pode ser visto no segundo  
219 arquivo apresentado no link: <https://gist.github.com/danielfariati/1535513>. A figura 3 mostra alguns resultados deste algoritmo. Percebe-se  
220 que, quanto maior a entrada, mais tempo o algoritmo de Las Vegas ficará  
221



222 executando. Já o algoritmo de Monte Carlo recebe um número limitado de  
 223 tentativas, mas pode não encontrar a solução correta neste intervalo. Caso  
 224 não encontre, o algoritmo tenta fazer um cálculo para retornar uma previsão.  
 225 Este cálculo é dado somente para demonstrar que o Monte Carlo pode res-  
 226 ponder valores incorretos, visto que o cálculo poderia ser mais aperfeiçoado  
 227 para responder a previsão com mais precisão, como por exemplo, lidando  
 228 melhor se o número secreto fosse algum dos extremos, como o número 1.

Figura 3: (a) Execução 1, (b) Execução 2, (c) Execução 3 e (d) Execução 4



## 229 5. Aplicações

230 Os algoritmos probabilísticos tem sido utilizados em uma grande varie-  
 231 dade de aplicações, principalmente devido à dois dos seus maiores benefícios:  
 232 simplicidade e rapidez [1].

233 Com o intuito de apresentar algumas de suas aplicações e com base na  
 234 explanação em [7], essa seção explora dois algoritmos probabilísticos: o teste  
 235 de primalidade e o teste de equivalência de programas ramificantes.

### 236 5.1. Teste de Primalidade

237 O problema de determinar se um número é primo ou não sempre foi alvo  
 238 de pesquisas devido às suas diversas aplicações. Em 2002, foi publicado o  
 239 artigo [22] que prova que esse problema pertence à classe P ao descobrir um  
 240 algoritmo determinístico que o resolve em tempo polinomial.

241 Anteriormente, alguns algoritmos probabilísticos foram propostos para  
 242 determinar a primalidade de um número. Estes algoritmos tem como base o  
 243 pequeno teorema de Fermat apresentado a seguir.

244 **TEOREMA.** Se  $p$  é um número primo e  $a \in Z^+$  é não divisível e menor  
 245 que  $p$ , então  $a^{p-1} \equiv 1 \pmod{p}$ .

246 O problema em utilizar o teorema como um teste de primalidade é que  
 247 existem certos números compostos, chamados números de Carmichael, que  
 248 comportam-se como primos e passam nos testes para todos os valores de  $a$ .  
 249 Assim, o teste de Fermat é considerado um algoritmo probabilístico: se  $p$  não  
 250 passa no teste para algum valor de  $a$ ,  $p$  certamente é um número composto  
 251 (não primo); se  $p$  passa no teste para todos os valores de  $a$  analisados,  $p$   
 252 quase certamente é primo (mas pode ser um número de Charmichael), por  
 253 isso, dizemos que  $p$  possui um caráter pseudoprimo.

254 Conforme descrito em [7], uma máquina de Turing probabilística para  
 255 testar o caráter pseudoprimo é apresentada a seguir:

256

257 MTP = Sobre a entrada  $p$

- 258 1. Selecione  $a_1, a_2, \dots, a_k$  tal que  $a \in \mathbb{Z}^+$  é menor e não divisível por  $p$ .
- 259 2. Calcule  $a_i^{p-1}$  para cada  $i$ .
- 260 3. Se todos os resultados forem 1, aceite. Caso contrário, rejeite.

261

262 É possível observar que se  $p$  for pseudoprimo (um número primo ou um  
 263 número de Charmichael), ele passa em todos os testes e é aceito. Se  $p$  não  
 264 for pseudoprimo, ele passa em cada teste com probabilidade de  $\frac{1}{2}$ , logo, a  
 265 probabilidade de que ele passe em todos  $k$  testes é  $2^{-k}$  [7].

266 Para resolver o problema dos números de Charmichael, um outro teste é  
 267 adicionado ao algoritmo. Sabe-se que o número 1 possui apenas duas raízes  
 268 quadradas (1 e -1) módulo de um primo  $p$  qualquer. Para os números com-  
 269 postos, incluindo os números de Charmichael, 1 possui quatro ou mais raízes  
 270 quadradas módulo  $p$ . Por isso, é possível criar um algoritmo de primalidade  
 271 que encontra a raiz quadrada de 1 e verifica se ela é 1 ou -1, se não for, deter-  
 272 mina que o número não é primo. Para encontrar cada raiz o cálculo feito é  
 273  $a^{(p-1)/2} \bmod p$ . Se o valor encontrado for 1, é possível dividir o expoente por  
 274 2 até encontrar um valor diferente. Se o valor encontrado for -1, o número é  
 275 primo, caso contrário, o número é composto [7].

276

277 MTP = Sobre a entrada  $p$

- 278 1. Se  $p$  for par, aceite caso  $p = 2$  e rejeite caso contrário.
- 279 2. Selecione  $a_1, a_2, \dots, a_k$  aleatoriamente tal que  $a \in \mathbb{Z}^+$  é menor e não  
 280 divisível por  $p$ .
- 281 3. Para cada  $i$  faça:
- 282 4. Calcule  $a_i^{p-1} \bmod p$  e rejeite se for diferente de 1.
- 283 5. Faça  $s = p - 1$  com  $s$  ímpar e  $t$  uma potência de 2.


- 284 6. Calcule a sequência  $a_i^s \cdot 2^0, a_i^s \cdot 2^1, \dots, a_i^s \cdot 2^h$  módulo  $p$ .  
 285 7. Se algum resultado da sequência não for 1, encontre o último elemento  
 286 diferente de 1 e verifique se ele é -1. Se não for, rejeite.  
 287 8. Se os testes passaram até aqui, aceite.

288  
 289 Sipser em [7] demonstra ainda que se  $p$  é primo, o algoritmo o identifica  
 290 corretamente com probabilidade 1. E se  $p$  é composto, a probabilidade de  
 291 erro é menor que  $2^{-k}$ . Assim, esse algoritmo pertence à classe BPP.

292 Sobre o problema da primalidade de um número, pode-se definir sua  
 293 maior aplicação dentro da Criptografia, principalmente nos sistemas basea-  
 294 dos em chaves públicas e privadas. A Criptografia RSA, por exemplo, gera  
 295 suas chaves a partir da multiplicação de dois números primos grandes ( $p$   
 296 e  $q$ ), assim, garante-se que o processo de fatoração desse número será o  
 297 mais difícil possível. Os algoritmos para testar o caráter primo de  $p$  e  $q$   
 298 são probabilísticos, sendo os mais conhecidos o teste de Miller Rabin e de  
 299 Solovay–Strassen [23].

## 300 5.2. Equivalência de programas ramificantes

Figura 4: Programa ramificante



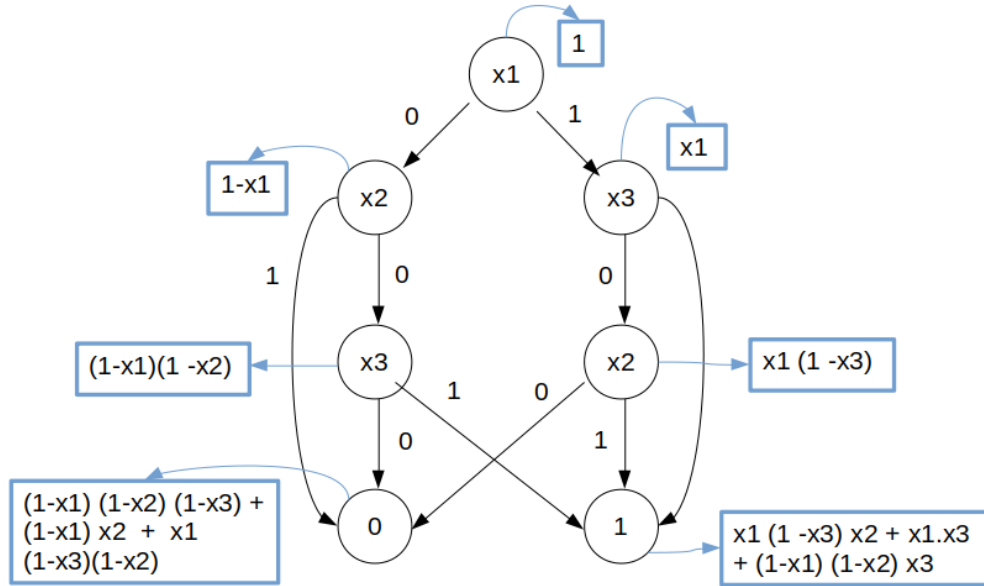
301 Um programa ramificante (*branching program*) é um grafo direcionado  
 302 acíclico cujos vértices representam variáveis, exceto por dois nós de saída  
 303 rotulados 0 e 1 [7]. Cada nó que representa uma variável possui grau de  
 304 saída 2, com uma aresta rotulada como 1 e outra rotulada como 0. Esse

305 programa determina uma função booleana ao sair do nó inicial e seguir o  
 306 caminho indicado por cada aresta de acordo com a valoração das variáveis  
 307 [24]. A Figura 4 apresenta um exemplo desse tipo de programa.

308 O problema de determinar a equivalência de dois programas ramifican-  
 309 tes tem como objetivo determinar se dados dois programas B1 e B2, eles  
 310 determinam as mesmas funções.

311 A prova para esse problema baseia-se em associar um polinômio para  
 312 cada um dos  $m$  nós e arestas dos programas da seguinte forma: a constante  
 313 1 é atribuída ao nó inicial; se um  $x$  é atribuído a um nó, deve ser atribuído  
 314  $xp$  à sua aresta de saída com rótulo 1 e  $(1 - x)p$  à sua aresta de saída  
 315 com rótulo 0. Atribui-se também a cada nó a soma das suas arestas de  
 316 entrada. E o polinômio atribuído ao nó de saída 1 é também atribuído ao  
 317 próprio programa ramificante redSipser. A figura 5 apresenta a atribuição  
 318 de polinômios ao programa ramificante apresentado anteriormente.

Figura 5: Atribuição de polinômios ao programa ramificante



319 A partir dessa atribuição, é possível apresentar o seguinte algoritmo pro-  
 320 babilístico:

321

322 MTP = Sobre a entrada  $\langle B1, B2 \rangle$

- 323 1. Selecione elementos  $a_1, \dots, a_m$  de um conjunto  $F$  com no mínimo  $3m$   
324 elementos.  
325 2. Calcule o valor dos polinômios  $p_1$  e  $p_2$  em cada um dos  $m$  elementos.  
326 3. Se  $p_1(a_1, \dots, a_m) = p_2(a_1, \dots, a_m)$ , aceite. Caso contrário, rejeite.

327

328 Sipser em [7] demonstra que caso os programas B1 e B2 sejam equivalen-  
329 tes, MTP sempre aceita a entrada. E caso contrário, MTP rejeita com uma  
330 probabilidade de erro de  $\frac{1}{3}$ . Assim, este algoritmo pertence à BPP.

331 Os programas ramificantes possuem sua maior aplicação dentro de sis-  
332 temas computacionais relacionados ao Desenho Assistido por Computador  
333 (CAD). Principalmente no que diz respeito à verificação de circuitos combi-  
334 nacionais e teste de padrões [24].

## 335 6. Considerações Finais

336 Este artigo apresentou uma pesquisa bibliográfica com o objetivo de  
337 conceituar a máquina de Turing probabilística e suas classes de complexi-  
338 dade, bem como relatar a classificação dos algoritmos probabilísticos e suas  
339 aplicações. Foi possível constatar que muitas classes de complexidade são de-  
340 finidas em torno da máquina de Turing probabilística e que ainda há questões  
341 abertas acerca destas classes, sendo uma considerada igualmente importante  
342 a questão de  $N = NP$ , dada por descobrir se  $BPP = P$ . A utilização dos algorit-  
343 mos probabilísticos é vista como um grande potencial, dado que com algorit-  
344 mos probabilísticos é possível resolver problemas que ainda não descobriu-se  
345 uma maneira possível de resolver com algoritmos determinísticos. Portanto,  
346 há uma forte tendência deste tipo de computação continuar sendo gradati-  
347 vamente discutida e aprimorada.

## Referências

- [1] R. Motwani, Randomized algorithms, ACM Computing Surveys (CSUR) 28 (1996) 33 – 37.
- [2] K. D. Leeuw, E. F. Moore, C. E. Shannon, N. Shapiro, Computability by probabilistic machines, Automata Studies, Annals of Mathematics Studies (1956) 183 – 212.
- [3] M. O. Rabin, Probabilistic automata, Information and Control 6 (1963) 230 – 245.

- [4] E. S. Santos, Probabilistic turing machines and computability, *Proceedings of the American Mathematical Society* 22 (1969) 704 – 710.
- [5] J. T. Gill, Computational complexity of probabilistic turing machines, *SIAM J. Comput.* 6 (1977) 675 – 695.
- [6] A. M. Turing, On computable numbers, with an application to the Entscheidungs problem, *Proceedings of the London Mathematical Society* (1937) 230 – 265.
- [7] M. Sipser, *Introdução à Teoria da Computação*, Cengage Learning, 2016.
- [8] D. Mandrioli, C. A. Furia, M. Rossi, A. Morzenti, *Modeling Time in Computing*, Springer, 2012.
- [9] O. Goldreich, *Computational Complexity: A Conceptual Perspective*, Cambridge University Press, 1<sup>a</sup> edition, 2008.
- [10] *Computational Complexity: A Modern Approach*, <http://theory.cs.princeton.edu/complexity/bppchap.pdf>, 2007. Acessado em: 19 jun. 2019.
- [11] *Randomized Algorithms*, <https://www.cs.cmu.edu/afs/cs/academic/class/15859-f04/www/scribes/lec2.pdf>, 2019. Acessado em: 19 jun. 2019.
- [12] *Bounded Probabilistic Polynomial*, <https://www.csie.ntu.edu.tw/~lyuu/complexity/2015/2015-2015>. Acessado em: 19 jun. 2019.
- [13] D.-Z. Du, K.-I. Ko, *Theory of Computational Complexity*, John Wiley Sons, 1<sup>a</sup> edition, 2008.
- [14] H. Hempel, Randomized algorithms and complexity theory, *Journal of Universal Computer Science* 12 (2006) 746–761.
- [15] I. Kononenko, M. Kukar, *Machine Learning and Data Mining*, Woodhead Publishing, 2007.
- [16] T. A. Rocha, Complexidade descritiva de classes probabilísticas de tempo polinomial e das classes  $p$  e  $np_{conp}$  através de lógicas com quantificadores generalizados de segunda ordem, *Dissertação(Ciência da Computação) - Universidade Federal do Ceará, Departamento de Computação* (2014).

- [17] Complexity Classes, <https://brilliant.org/wiki/complexity-classes/>, 2019. Acessado em: 19 jun. 2019.
- [18] Computational Complexity, <https://people.eecs.berkeley.edu/luca/cs278-04/notes/lecture08.pdf>, 2002. Acessado em: 19 jun. 2019.
- [19] D. Antonova, D. Kunkle, Theory of randomized computation: A survey for csg714, Northeastern University, Boston (2005).
- [20] C. de Figueiredo, G. da Fonseca, M. Lemos, V. de Sá, Computational Complexity: A Conceptual Perspective, Associação Instituto Nacional de Matemática Pura e Aplicada - IMPA, 2007.
- [21] Algoritmos Las Vegas - Monte Carlo, <https://gist.github.com/danielfariati/1535513>, 2011. Acessado em: 19 jun. 2019.
- [22] M. Agrawal, N. Kayal, N. Saxena, Primes is in p, Annals of Mathematics (2004) 781 – 793.
- [23] Notes on primality testing and public key cryptography part 1: Randomized algorithms miller–rabin and solovay–strassen tests, <http://www.cis.upenn.edu/jean/RSA-primality-testing.pdf>, 2019. Accessed: 2019-05-19.
- [24] I. Wegener, Branching Programs and Binary Decision Diagrams: Theory and Applications, 1987.